

Міністерство освіти та науки України
Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»
Радіотехнічний факультет
Кафедра прикладної радіоелектроніки

Звіт
про лабораторну роботу №3 за темою
«Злам шифру Цезаря частотним аналізом»
з дисципліни
«Захист даних»

Викладач:

Навроцький Денис Олександрович

Виконав:

Студент групи РС-61мн

Гандзюк Дмитро Васильович

Київ – 2026 р.

Лабораторна робота №3

Злам шифру Цезаря частотним аналізом

Мета роботи: на прикладі шифру Цезаря з'ясувати, як статистичні властивості природної мови дозволяють прочитати шифротекст без знання ключа; реалізувати такий злам, підтвердити його коректність на офіційних валідаторах платформи CodinGame та кількісно оцінити, скільки тексту потрібно різним вирішальним правилам для надійного визначення ключа.

Хід роботи

Постановка задачі

Задача взята з навчальної платформи CodinGame (розділ Training, рівень складності Medium) і має назву «Frequency-Based Decryption». На відміну від попередньої лабораторної роботи, тут не потрібно писати шифратор: на вхід подається вже зашифроване повідомлення, ключ не надається, і його треба відновити самостійно.

Формат даних задачі:

вхід : один рядок — повідомлення, зашифроване зсувом
вихід : один рядок — розшифроване повідомлення
обмеження: $67 \leq \text{довжина повідомлення} < 1000$

Умова накладає три додаткові вимоги. По-перше, зсув застосовується лише до літер: цифри, розділові знаки й пробіли залишаються на своїх місцях. По-друге, регістр літер має зберігатися. По-третє, еталонні частоти літер англійської мови задано безпосередньо в умові, і саме їх належить використовувати як еталон.

Приклад із умови:

вхід : Khoor Zruog ! Frqjudwxodwlrqv, brx kdyh vxffhvvixooob ...
вихід: Hello World ! Congratulations, you have successfully ...
ключ, знайдений частотним аналізом: $k = 3$

Окремо варто зробити термінологічне уточнення. В умові лабораторної роботи зсув названо перестановкою. У строгій класифікації шифрів циклічний зсув є *підстановкою* символів: він замінює кожну літеру іншою, але не змінює їхніх позицій у повідомленні; перестановний шифр, навпаки, переставляє самі символи (Handbook of Applied Cryptography, § 1.5.2). Далі в

роботі збережено термінологію умови.

Модель шифру та простір ключів

Позначимо літери числами від 0 до 25 і виконуватимемо всі операції за модулем 26. Шифрування та розшифрування записуються так:

$$\begin{aligned}c[i] &= (m[i] + k) \bmod 26 && \text{— лише для літер} \\m[i] &= (c[i] - k) \bmod 26\end{aligned}$$

Зсуви утворюють циклічну групу порядку 26: послідовне застосування зсувів a і b дорівнює одному зсуву $a + b$. Це перевірено окремим автоматичним тестом і має практичний наслідок — багаторазове шифрування цим шифром нічого не додає, бо зводиться до одного зсуву. Уся конфігурація шифру описується одним числом.

Таблиця 3.1 – Простір ключів шифру Цезаря

Величина	Значення
Кількість ключів	26
Ентропія ключа за рівноймовірного вибору, біт	4,70
Орієнтовна відстань єдиності ($h \approx 1,5$ біта/символ), символів	1,5

Відстань єдиності тут наведено як орієнтир у прийнятій моделі мови, а не як жорстку межу: вона не гарантує ні неможливості зламу коротших повідомлень, ні успіху конкретного алгоритму на довших. Наскільки ця оцінка відрізняється від практики, показано далі.

Головний наслідок такого розміру простору ключів полягає в тому, що злам цього шифру — **задача вибору, а не пошуку**. Перебрати всі 26 варіантів тривіально; уся складність зосереджена в тому, щоб автоматично вирішити, котрий із 26 кандидатів є осмисленим текстом. Саме різні вирішальні правила й порівнює ця робота.

Програмна реалізація

Розв’язок виконано мовою Python 3 і продубльовано мовою C# на платформі .NET 8 (незалежна реалізація для перехресної перевірки). Вихідний код самодостатнього розв’язку для платформи наведено в додатку А. Решта вихідних текстів — ядро шифру, модуль зламу, статистичні метрики, набір автоматичних тестів і реалізація мовою C# — доступні в

репозиторії роботи, посилання на який наведено в списку використаних джерел.

Реалізовано чотири вирішальні правила. Критерій **хі-квадрат** порівнює гістограму кандидата з еталонною таблицею з умови задачі (менше значення — краще). **Логправдоподібність за частотами літер** робить те саме в термінах правдоподібності. **Логправдоподібність за квадриграмами** враховує ще й порядок літер. Нарешті, **найвне правило** «найчастіша літера шифротексту відповідає Е» взагалі не перебирає кандидатів і слугує базовою лінією для порівняння.

Дрібна, але показова оптимізація в надісланому розв’язку: замість того щоб розшифровувати весь текст для кожного з 26 кандидатів, достатньо один раз побудувати гістограму шифротексту й циклічно зсувати її. Кожен кандидат тоді коштує 26 операцій замість L , а повне розшифрування виконується один раз — уже з відомим ключем.

Верифікація розв’язку

Правильність реалізації підтверджено на чотирьох незалежних рівнях: офіційними валідаторами платформи, збереженими в репозиторії офіційними тестами, набором властивісних тестів і перехресним порівнянням двох реалізацій різними мовами.

Розв’язок надіслано на перевірку платформі CodinGame: пройдено всі п’ять видимих тестів, а підсумкова оцінка прихованих валідаторів становить **100 %**. Надісланий код у вікні редактора наведено на рисунку 3.1, результат прогону тестів — на рисунку 3.2, підсумкову оцінку — на рисунку 3.3.

```

1
2 import sys
3
4 # Reference letter frequencies, in percent, exactly as given in the puzzle.
5 FREQ = [0.08, 1.67, 3.18, 3.99, 12.56, 2.17, 1.80, 5.27, 7.24, 0.14, 0.63,
6         4.04, 2.60, 7.38, 7.47, 1.91, 0.09, 6.42, 6.59, 9.15, 2.79, 1.00,
7         1.89, 0.21, 1.65, 0.07]
8
9 M = 26
10
11
12 def main() -> None:
13     message = sys.stdin.readline().rstrip("\n")
14
15     # Letter histogram of the ciphertext, case-insensitive.
16     counts = [0] * M
17     total = 0
18     for ch in message:
19         if "A" <= ch <= "Z":
20             counts[ord(ch) - 65] += 1
21             total += 1
22         elif "a" <= ch <= "z":
23             counts[ord(ch) - 97] += 1
24             total += 1
25
26     # Score every possible shift; shifting the histogram is equivalent to
27     # decrypting the whole message, but costs 26 operations instead of 1.
28     best_key, best_chi = 0, None
29     for k in range(M):
30         chi = 0.0
31         for i in range(M):
32             expected = total * FREQ[i] / 100.0
33             observed = counts[(i + k) % M]
34             chi += (observed - expected) ** 2 / expected
35         if best_chi is None or chi < best_chi:
36             best_key, best_chi = k, chi
37
38     # Decrypt with the winning key, preserving case and non-letters.
39     out = []
40     for ch in message:
41         if "A" <= ch <= "Z":
42             out.append(chr((ord(ch) - 65 - best_key) % M + 65))
43         elif "a" <= ch <= "z":
44             out.append(chr((ord(ch) - 97 - best_key) % M + 97))
45         else:

```

Рисунок 3.1 – Надісланий розв’язок у вікні редактора CodinGame

Test cases		
01	Test 1	▶ PLAY TEST
02	Test 2	▶ PLAY TEST
03	Test 3	▶ PLAY TEST
04	Test 4	▶ PLAY TEST
05	Test 5	▶ PLAY TEST

Рисунок 3.2 – Усі п’ять тестів платформи позначені як пройдені




Рисунок 3.3 – Звіт платформи: оцінка валідаторів — 100 %

Входи та еталонні виходи всіх п'яти тестів збережено в репозиторії у файлі `tests/official_cases.json`. Окремий тест перевіряє самоузгодженість цієї фікстури: записаний ключ має точно перетворювати очікуваний відкритий текст на збережений шифротекст, що виключає помилку переписування тестових даних. Перелік тестів наведено в таблиці 3.2.

Таблиця 3.2 – Офіційні тести CodinGame

№	Ключ	Довжина, символів	Результат
1	3	93	пройдено
2	8	227	пройдено
3	10	142	пройдено
4	14	119	пройдено
5	24	923	пройдено


У п'яти тестах використано п'ять різних ключів, тож вгадування одного зсуву тут не спрацювало б. П'ятий тест додатково перевіряє збереження типографського апострофа `U+2019` та інших не-літерних символів. Результат локального прогону:

```
$ python run.py selftest
Офіційні тести CodinGame
-----
[OK] Test 1  ключ 3 (істина 3)  Hello World ! Congratulations, ...
[OK] Test 2  ключ 8 (істина 8)  I rubbed shoulders with people ...
[OK] Test 3  ключ 10 (істина 10) You can fool all of the people ...
[OK] Test 4  ключ 14 (істина 14) Any code you've been writing ...
[OK] Test 5  ключ 24 (істина 24) Mr. and Mrs. Dursley, of number ...
-----
Пройдено 5 з 5
```

Окрім офіційних тестів, написано набір із 102 автоматичних тестів. Вони перевіряють оборотність перетворення на 500 випадкових рядках; групову властивість зсувів; недоторканність не-літерних символів, зокрема цифр, розділових знаків і кирилиці; збереження регістру; інваріантність індексу відповідності щодо зсуву та, навпаки, чутливість критерію хі-квадрат. Реалізація мовою C# відновлює ті самі відкриті тексти, а окремий тест порівнює вихід обох реалізацій символ у символ. Увесь набір виконується автоматично при кожній зміні коду засобами GitHub Actions на трьох версіях Python.

Що зсув робить із частотами літер

Почнемо з того, чому частотна атака взагалі можлива. Зашифруємо англomовний текст обсягом 2497 символів зсувом $k = 3$ і порівняємо гістограми відкритого тексту й шифротексту з еталонною таблицею з умови задачі (рисуюнок 3.4).



Рисуюнок 3.4 – Зсув не приховує статистику, а лише обертає гістограму

Результат принципово відрізняється від того, що спостерігалось в попередній лабораторній роботі. Там інкрементний зсув вирівнював частоти й робив розподіл майже рівномірним. Тут же фіксований зсув лише **обертає гістограму на k позицій**, не змінюючи її форми: найчастіша літера відкритого тексту Е переходить у літеру Н, тобто зсув піку точно дорівнює ключу. Кількісні показники наведено в таблиці 3.3.

Таблиця 3.3 – Статистика тексту до та після шифрування

Показник	Відкритий текст	Шифротекст
Найчастіша літера	Е	Н
Індекс відповідності	0,0707	0,0707
Хі-квадрат до таблиці з умови	54	15896
Емпірична ентропія окремих літер, біт	4,105	4,105

Індекс відповідності й ентропія окремих літер не змінилися зовсім — і це не випадковість, а точна властивість перестановки стовпчиків гістограми. Натомість хі-квадрат до еталонної таблиці зріс із 54 до 15896, бо гістограма тепер зіставляється з еталоном «не в тій фазі». Саме ця відмінність між двома метриками й лежить в основі атаки.

Профіль хі-квадрат по 26 кандидатах

Перебираємо всі 26 можливих ключів і для кожного кандидата обчислюємо статистику хі-квадрат між його гістограмою та еталонною таблицею:

$$\chi^2(k) = \text{SUM по літерах } (\text{спостережено} - \text{очікувано})^2 / \text{очікувано}$$

Результат для повідомлення завдовжки 400 символів наведено на рисунку 3.5.




Рисунок 3.5 – Значення хі-квадрат для 26 кандидатів; правильний ключ дає різкий мінімум

Правильний ключ виділяється однозначно: його значення хі-квадрат у 37,3 раза менше, ніж у наступного за якістю кандидата, а весь перебір триває 0,91 мілісекунди. Це типова картина для повідомлень такої довжини; поведінку на коротших текстах розглянуто далі.

Чому ключ дає хі-квадрат, а не індекс відповідності

Індекс відповідності — класичний інструмент криптоаналізу, і на перший погляд він мав би теж підійти. Проте ці дві метрики поведуться протилежно, і різниця між ними варта окремого розгляду. Застосуємо до одного тексту всі 26 зсувів і подивимося, як змінюються обидві величини (рисунок 3.6).




Рисунок 3.6 – Індекс відповідності не залежить від зсуву, а хі-квадрат залежить

Індекс відповідності не змінився взагалі: усі 26 значень збіглися до останнього знаку. Хі-квадрат натомість змінюється від 25 до 18642, тобто в 744 разів. Причина проста: зсув лише переставляє стовпчики гістограми, а індекс відповідності залежить тільки від їхнього набору, не від порядку. Хі-квадрат же порівнює гістограму з конкретним еталоном, і тому «відчуває» фазу.

Практичний висновок такий: індекс відповідності відповідає на запитання «який це тип шифру» (моноалфавітний чи ні) і не здатен дати ключ, а хі-квадрат — навпаки. У попередній лабораторній роботі саме індекс відповідності виявив поліалфавітну структуру; тут він лише підтверджує, що шифр моноалфавітний, а всю роботу щодо ключа виконує хі-квадрат.

Скільки тексту потрібно різним правилам рішення

Це основний експеримент роботи. Для кожної довжини повідомлення бралось 200 випадкових фрагментів корпусу, кожен шифрувався випадковим ключем, після чого всі чотири правила намагалися цей ключ відновити. Результати наведено на рисунку 3.7 і в таблиці 3.4.




Рисунок 3.7 – Частка правильно знайдених ключів залежно від довжини повідомлення

Таблиця 3.4 – Частка правильно знайдених ключів, % (по 200 випробувань на точку)

Правило рішення	5	10	15	20	40	120	200
Квадриграми	74,0	99,5	100,0	100,0	100,0	100,0	100,0
Частоти літер	46,0	80,5	94,5	97,5	100,0	100,0	100,0
Хі-квадрат	43,0	75,0	89,5	90,5	100,0	100,0	100,0
Найчастіша → E	18,0	27,0	37,5	41,0	52,0	92,0	96,5

У цій серії випробувань квадриграми першими досягли 100 % — уже на довжині 15 символів; хі-квадрат і логправдоподібність за частотами літер досягли 100 % на 40 символах, а найвне правило не досягло 100 % навіть на 200 символах (96,5 %). Перевага квадриграм на коротких текстах закономірна: вони враховують не лише частоти літер, а й порядок, у якому ті стоять.

Зіставимо це з теоретичною оцінкою. Відстань єдиності для 26 ключів становить близько 1,5 символу, тобто інформації в шифротексті вистачає майже одразу. Практичні ж 15–40 символів — це розрив між інформаційно-теоретичною оцінкою та можливостями конкретного вирішального правила; наведені числа характеризують саме цю серію випробувань на використаному корпусі.

Для умови задачі це означає, що гарантована довжина повідомлення $L \geq 67$ із великим запасом перекриває поріг усіх трьох статистичних правил. Саме тому надісланий розв’язок із простим критерієм хі-квадрат проходить валідатори.

Чому помиляється найвне правило

Правило «найчастіша літера шифротексту відповідає Е» цікаве тим, що помиляється не випадково, а строго передбачувано: його похибка точно дорівнює зсуву найчастішої літери *відкритого* тексту відносно Е. Розподіл похибки на повідомленнях по 40 символів (2000 випробувань) наведено на рисунку 3.8.




Рисунок 3.8 – Розподіл похибки найвного правила визначення ключа

Таблиця 3.5 – Найчастіша літера у фрагментах відкритого тексту

Літера	Е	А	О	решта
Частка випробувань, %	61,4	12,3	6,6	19,7

Точність правила склала 57,4 %, що добре узгоджується з часткою фрагментів, у яких найчастішою літерою справді виявилася Е (61,4 %). Методичний висновок очевидний: правило спирається рівно на одне спостереження, тоді як хі-квадрат використовує всі 26 і тому стійкіший до випадкових коливань.

Коли частотна атака перестане працювати

У постановці лабораторної роботи є пряма вимога: шифрограми мають бути без статистичних закономірностей, притаманних звичайному тексту. Перевіримо її експериментально. Зашифруємо один і той самий відкритий текст двома способами: звичайним зсувом Цезаря та зсувом, що для кожної позиції обирається випадково й незалежно. Профілі χ^2 -квадрат наведено на рисунку 3.9.




Рисунок 3.9 – Частотна атака працює лише тоді, коли шифр лишає статистичний слід

Таблиця 3.6 – Порівняння двох способів шифрування одного тексту

Шифр	Мін. χ^2 -квадрат	Макс. χ^2 -квадрат	Контраст	ІоС шифротексту
Цезар (один зсув)	25	18642	744×	0,0699
Випадковий зсув на кожну позицію	1743	4690	2,7×	0,0392

У другому випадку профіль χ^2 -квадрат майже плаский: жоден кандидат не виділяється, а індекс відповідності падає до 0,0392, тобто до значення рівномірного розподілу. Частотна атака перестає працювати не тому, що стала обчислювально складнішою, а тому, що в шифротексті не лишилося сліду, за який вона чіплялася.

Це, звісно, не робить такий шифр придатним на практиці: ключ у ньому завдовжки з саме повідомлення, і його ще треба якось передати одержувачу. Демонстрація показує лише те, на чому саме тримається частотний аналіз, і тим самим пояснює наведену в умові вимогу до шифрограм.

Висновки

1. Реалізовано злам шифру Цезаря без знання ключа. Розв'язок надіслано на CodinGame: пройдено п'ять видимих тестів, оцінка прихованих валідаторів — 100 %. Реалізацію продубльовано двома мовами (Python і C#) та покрито 102 автоматичними тестами.

2. Злам цього шифру є задачею вибору, а не пошуку: простір ключів містить 26 варіантів, що відповідає ентропії 4,70 біта, тому перебір тривіальний, і вся складність зосереджена у вирішальному правилі.

3. Зсув зберігає форму частотного розподілу, лише обертаючи гістограму на k позицій. Індекс відповідності при цьому не змінюється зовсім — усі 26 значень збігаються до останнього знаку, — а χ^2 змінюється у 744 разів. Саме тому ключ дає χ^2 , а індекс відповідності здатен вказати лише на тип шифру.

4. Вирішальні правила істотно різняться за вимогами до обсягу тексту. У проведеній серії квадриграми досягли 100 % на довжині 15 символів, χ^2 і частоти літер — на 40 символах, а наївне правило «найчастіша $\rightarrow$ E» не досягло 100 % і на 200 символах.

5. Похибка наївного правила має регулярну природу: вона дорівнює зсуву найчастішої літери відкритого тексту відносно E. Тому його точність (57,4 % на фрагментах по 40 символів) майже збігається з часткою фрагментів, у яких найчастішою літерою справді є E.

6. Вимогу умови щодо відсутності статистичних закономірностей підтверджено вимірюванням: для шифру Цезаря контраст між найкращим і найгіршим кандидатом склав 744 разів, а для шифру з випадковим зсувом на кожну позицію — лише 2,7 раза, і атака перестала розрізняти кандидатів.

7. Практичний урок роботи: стійкість шифру визначає не розмір алфавіту й не зовнішня заплутаність перетворення, а те, чи лишає шифротекст статистичний слід відкритого тексту.

Список використаних джерел

1. CodinGame. Frequency-Based Decryption [Електронний ресурс]. – Режим доступу:
<https://www.codingame.com/training/medium/frequency-based-decryption>
2. Caesar cipher [Електронний ресурс] // Wikipedia. – Режим доступу:
https://en.wikipedia.org/wiki/Caesar_cipher
3. Frequency analysis [Електронний ресурс] // Wikipedia. – Режим доступу:
https://en.wikipedia.org/wiki/Frequency_analysis
4. Index of coincidence [Електронний ресурс] // Wikipedia. – Режим доступу:
https://en.wikipedia.org/wiki/Index_of_coincidence
5. Menezes A., van Oorschot P., Vanstone S. Handbook of Applied Cryptography, § 1.5. – CRC Press, 1996. – Режим доступу:
<https://cacr.uwaterloo.ca/hac/about/chap1.pdf>
6. Shannon C. E. Communication Theory of Secrecy Systems // Bell System Technical Journal. – 1949. – Vol. 28, No. 4. – P. 656–715.
7. Beker H., Piper F. Cipher Systems: The Protection of Communications. – London: Northwood Books, 1982. – 436 p.
8. Вихідний код роботи [Електронний ресурс]. – Режим доступу:
<https://github.com/RE22GDV/LR3-Frequency>

Додаток А

Розв'язок задачі, надісланий на платформу CodinGame

Нижче наведено повний текст файла `solution/codingame_solution.py` — саме цей код надіслано на платформу CodinGame й оцінено валідаторами на 100 %. Решта вихідних текстів роботи (ядро шифру, модуль зламу з чотирма правилами рішення, статистичні метрики, набір зі 102 автоматичних тестів, скрипти експериментів і незалежна реалізація мовою C#) не наводиться тут, щоб не переобтяжувати звіт, і доступна в репозиторії: <https://github.com/RE22GDV/LR3-Frequency>

```
"""
CodinGame - "Frequency-Based Decryption" (Medium)
https://www.codingame.com/training/medium/frequency-based-decryption

Self-contained solution, submitted as-is.
This file is kept ASCII-only and byte-identical to the accepted submission;
the Ukrainian write-up lives in README.md and in src/freqcrack/.

Task: an English text was encrypted with a Caesar shift. The key is NOT
given. Recover it by letter-frequency analysis and print the plaintext,
preserving letter case and leaving non-alphabetic characters untouched.

Method: the key space has only 26 elements, so this is a decision problem
rather than a search. Every candidate shift is scored with the chi-squared
statistic against the reference frequency table supplied by the puzzle,
and the candidate with the smallest value wins.

    chi2(k) = sum over letters of (observed - expected)^2 / expected

Time O(26 * L), extra memory O(26).
"""

import sys

# Reference letter frequencies, in percent, exactly as given in the puzzle.
FREQ = [8.08, 1.67, 3.18, 3.99, 12.56, 2.17, 1.80, 5.27, 7.24, 0.14, 0.63,
        4.04, 2.60, 7.38, 7.47, 1.91, 0.09, 6.42, 6.59, 9.15, 2.79, 1.00,
        1.89, 0.21, 1.65, 0.07]

M = 26

def main() -> None:
    message = sys.stdin.readline().rstrip("\n")

    # Letter histogram of the ciphertext, case-insensitive.
    counts = [0] * M
    total = 0
    for ch in message:
        if "A" <= ch <= "Z":
            counts[ord(ch) - 65] += 1
            total += 1
        elif "a" <= ch <= "z":
            counts[ord(ch) - 97] += 1
```

```

        total += 1

# Score every possible shift; shifting the histogram is equivalent to
# decrypting the whole message, but costs 26 operations instead of L.
best_key, best_chi = 0, None
for k in range(M):
    chi = 0.0
    for i in range(M):
        expected = total * FREQ[i] / 100.0
        observed = counts[(i + k) % M]
        chi += (observed - expected) ** 2 / expected
    if best_chi is None or chi < best_chi:
        best_key, best_chi = k, chi

# Decrypt with the winning key, preserving case and non-letters.
out = []
for ch in message:
    if "A" <= ch <= "Z":
        out.append(chr((ord(ch) - 65 - best_key) % M + 65))
    elif "a" <= ch <= "z":
        out.append(chr((ord(ch) - 97 - best_key) % M + 97))
    else:
        out.append(ch)

print("".join(out))

if __name__ == "__main__":
    main()

```